

Integración de IA Generativa Multimodal en la Interacción Humano-Robot (HRI) para Robótica Social (2020–2026)

Alejandro Valentino Seminario Medina^[0009–0006–5378–9115] and Alvaro Jordy Ordaya Zapata^[0009–0005–0751–5474]

Universidad Tecnológica del Perú, Piura, Perú
U22247454@utp.edu.pe, U20303695@utp.edu.pe

Resumen La incorporación de modelos generativos multimodales en la robótica social transformó la interacción humano-robot entre 2020 y 2026, pero la evidencia documenta limitaciones técnicas (latencia, errores de reconocimiento de voz y desincronización entre habla y gesto), cognitivas (fragilidad de la Teoría de la Mente y del razonamiento espacial) y éticas (sobre-antropomorfización y vulnerabilidad a la manipulación conversacional). Este avance presenta la metodología de una revisión sistemática de literatura (RSL) orientada a sistematizar las arquitecturas de fusión sensorial y de traducción de lenguaje a acción que abordan estas limitaciones. Se formuló una pregunta PICO, se definieron palabras clave controladas y una ecuación de búsqueda booleana que se aplicó de forma equivalente en Semantic Scholar y Crossref, y se seleccionaron los estudios conforme a la lógica de la declaración PRISMA 2020. De 942 registros identificados se eliminaron 64 duplicados, se cribaron 592 registros por título y resumen, se buscaron 95 informes a texto completo, se leyeron los 37 recuperables y se incluyeron 22 estudios primarios publicados entre 2023 y 2026.

Keywords: Robótica social · Interacción humano-robot · IA generativa multimodal · Robots socialmente asistidos · Revisión sistemática · PRISMA.

1. Introducción

En el campo de la interacción humano-robot (HRI) aplicada a la robótica social, la integración de la inteligencia artificial generativa multimodal ha cobrado relevancia entre 2020 y 2026. La aparición de los modelos de lenguaje de gran tamaño (LLM) y de arquitecturas capaces de procesar texto, voz, imágenes y video de forma conjunta desplazó el diálogo basado en gramáticas cerradas y árboles de decisión por respuestas contextuales no anticipadas por el diseñador. Zhang y Soh (2023) señalan que un LLM puede operar como modelo humano *zero-shot*; Kim et al. (2024) muestran que estos modelos reconfiguran las expectativas de diseñadores y usuarios; y Lai et al. (2025) evidencian, con la

arquitectura NVP-HRI, la viabilidad de fusionar voz y postura en plataformas físicas.

No obstante, la literatura presenta limitaciones. En el plano técnico, la memoria externa mediante generación aumentada por recuperación introduce retrasos de entre seis y quince segundos (Mauliana et al., 2025), los errores del reconocimiento automático de voz se concentran en hablantes no nativos y el modelo los encubre con respuestas plausibles (Verhelst y Belpaeme, 2025), y la voz expresiva y la gesticulación se generan en flujos independientes (Barakat et al., 2024). En el plano cognitivo, la Teoría de la Mente atribuida a los LLM se degrada ante perturbaciones triviales (Verma et al., 2024) y la falta de razonamiento espacial induce planes motores inseguros (Lai et al., 2025). En el plano ético, la expresividad del robot propicia la sobre-antropomorfización (Abercrombie et al., 2023) y los usuarios recurren al *gaslighting* o al *roleplay* para vulnerar sus resguardos (Abbo et al., 2025). Las revisiones previas abordan estos aspectos por separado (Barakat et al., 2024; Maure y Bruno, 2025) y no cubren la evidencia de 2024–2026.

El objetivo de la RSL es sistematizar el estado del arte sobre la integración de IA generativa multimodal en la HRI para robótica social entre 2020 y 2026, con énfasis en las arquitecturas propuestas para mitigar la latencia, sincronizar la comunicación no verbal y garantizar la gobernanza ética de la interacción. El presente avance describe la metodología seguida para identificar y seleccionar los estudios.

2. Metodología

2.1. Tipo de estudio y protocolo

Se realizó una revisión sistemática de literatura siguiendo las directrices de Kitchenham y Charters (2007) para ingeniería de software y la lógica de selección y reporte de la declaración PRISMA 2020 (Page et al., 2021). El proceso comprendió cinco fases: (1) formulación de la pregunta mediante la estrategia PICO; (2) definición de palabras clave y construcción de la ecuación de búsqueda; (3) definición de los criterios de elegibilidad; (4) búsqueda en bases de datos científicas y exportación de registros a Excel; y (5) selección sistemática de estudios documentada en un diagrama de flujo PRISMA. La búsqueda, la eliminación de duplicados y la aplicación de filtros se ejecutaron mediante scripts reproducibles que acompañan a la base de datos en Excel.

2.2. Pregunta de investigación (estrategia PICO)

La estrategia PICO permite descomponer la pregunta de investigación en componentes que se traducen directamente en términos de búsqueda (Santos et al., 2007). La Tabla 1 presenta los componentes y sus palabras clave. La pregunta formulada es:

En robots sociales, socialmente asistivos y de compañía (P), ¿qué arquitecturas de integración de IA generativa multimodal —fusión sensorial y traducción de lenguaje a acción con LLM o VLM— (I), frente a los enfoques de diálogo guionado o unimodal (C), se han propuesto y qué resultados reportan sobre la latencia de respuesta, la sincronización de la comunicación no verbal, el desempeño cognitivo y la gobernanza ética de la interacción (O)?

Tabla 1. Componentes de la pregunta PICO y palabras clave asociadas.

Comp.	Descripción	Palabras clave (inglés)
P	Robots sociales, socialmente asistivos y de compañía en HRI	“social robot”, “social robotics”, “socially assistive robot”, “companion robot”, “human-robot interaction”
I	IA generativa multimodal: LLM, VLM y modelos fundacionales integrados al robot	“large language model”, “generative AI”, “generative artificial intelligence”, “vision-language model”, “foundation model”, “GPT”, “ChatGPT”, “multimodal LLM”
C	Diálogo guionado, basado en reglas o unimodal	No se incluye en la ecuación (componente no esencial que restringe en exceso los resultados)
O	Latencia, sincronización verbal–no verbal, ToM y razonamiento espacial, confianza, antropomorfización, manipulación y seguridad	Se evalúa en el cribado (criterio CI4), no en la ecuación

2.3. Palabras clave

Las palabras clave se obtuvieron de la ficha del tema de investigación y de los términos empleados en los títulos, resúmenes y descriptores de los estudios de referencia (Kim et al., 2024; Lai et al., 2025; Maure y Bruno, 2025). La Tabla 2 muestra los términos principales en español e inglés y sus sinónimos.

2.4. Ecuación de búsqueda

Los sinónimos de cada componente se agruparon con el operador **OR**, y los componentes P e I se unieron con **AND**. Los componentes C y O se excluyeron de la ecuación porque su inclusión reducía los resultados a conjuntos truncos. Se aplicaron en el cribado mediante los criterios de elegibilidad. La ecuación genérica es:

Tabla 2. Palabras clave especializadas y sinónimos.

Español	Inglés	Sinónimos / variantes
Robótica social	Social robotics	social robot(s)
Robots socialmente asistivos	Socially assistive robots	companion robot(s)
Interacción humano-robot	Human-robot interaction	HRI
IA generativa multimodal	Multimodal generative AI	generative AI, multimodal LLM, vision-language model
Modelos de lenguaje de gran tamaño	Large language models	LLM, GPT, ChatGPT, foundation model

```
("social robot*" OR "social robotics" OR "socially assistive
robot*" OR "companion robot*" OR "human-robot interaction") AND
("large language model*" OR "generative AI" OR "generative
artificial intelligence" OR "vision-language model*" OR
"foundation model*" OR GPT OR ChatGPT OR "multimodal LLM")
```

Esta ecuación canónica se aplica sin cambios en todas las bases de datos; solo varía el campo de búsqueda y la forma de aplicar los filtros (Tabla 3):

- **Scopus.** La ecuación se pega en la caja *Search documents* con el campo *Article title, Abstract, Keywords*. Se aplican los filtros *Year range* 2020–2026, *Document type* Article y Conference Paper, y *Language* English y Spanish. Su forma en la búsqueda avanzada es:
TITLE-ABS-KEY(<ecuación>) AND PUBYEAR > 2019 AND PUBYEAR < 2027 AND (LIMIT-TO(DOCTYPE,"ar") OR LIMIT-TO(DOCTYPE,"cp")) AND (LIMIT-TO(LANGUAGE,"English") OR LIMIT-TO(LANGUAGE,"Spanish"))
- **Web of Science Core Collection.** En la *Fielded Search* se elige el campo *Topic* y se pega la ecuación tal cual, *sin* el prefijo TS=, porque el campo ya lo aplica. Se fija *Publication Date* del 2020-01-01 al 2026-12-31. Su equivalente en el *Query Builder* es TS=(<P>) AND TS=(<I>).
- **Semantic Scholar.** El operador + equivale a AND y | a OR. Las formas plurales se escriben explícitamente porque no admite truncamiento con *. La búsqueda se hace en título y resumen, con años 2020–2026.
- **Crossref.** Su API no admite operadores booleanos, por lo que se ejecutaron las 30 combinaciones P×I. Después se aplicó la misma ecuación sobre el título y el resumen de cada registro, de modo que el resultado es lógicamente equivalente.

2.5. Criterios de inclusión y exclusión

Los criterios de elegibilidad se derivaron de los componentes de la pregunta PICO (Tabla 4) y se aplicaron tanto en el cribado por título y resumen como en

Tabla 3. Aplicación de la ecuación canónica por base de datos.

Base	Campo	Filtros	Registros
Semantic Scholar	Título y resumen (API <i>bulk search</i>)	2020–2026; ejecución 3/10/2026	873
Crossref	Título y resumen (API REST, filtro booleano local)	2020–2026; ejecución 3/10/2026	69
Scopus	Article title, Abstract, Keywords	2020–2026; Article y Conference Paper; English y Spanish	Por ejecutar
WoS Core Collection	Topic (Fielded Search, sin TS=)	Publication Date 2020-01-01 a 2026-12-31	Por ejecutar
Total identificado 942			

la evaluación de elegibilidad. El periodo 2020–2026 no es arbitrario. Comienza con la publicación de los primeros LLM generativos de propósito general, que habilitaron la conversación abierta en robots sociales, y cubre la evidencia posterior a la ventana de las revisiones previas (Barakat et al., 2024; Maure y Bruno, 2025).

2.6. Búsqueda sistemática y base de datos de resultados

La búsqueda se ejecutó el 3 de octubre de 2026 en Semantic Scholar, mediante su API de búsqueda masiva sobre título y resumen (Kinney et al., 2023), y en Crossref, mediante su API REST (Hendricks et al., 2020). Los registros se exportaron a la hoja *Registros* del archivo *Base_de_datos.Seminario-Ordaga.xlsx*. Cada registro incluye el identificador, la base de origen, el título, los autores, el año, la fuente, el tipo de documento, el DOI y el resumen, así como la etapa PRISMA, la decisión y el criterio aplicado. La hoja *Ecuaciones* documenta la sintaxis, los filtros, la fecha y el número de registros de cada base, de modo que la búsqueda es reproducible.

2.7. Proceso de selección

La selección siguió los pasos de PRISMA 2020 (Page et al., 2021) y se documenta en la Fig. 1:

1. **Identificación.** Se recuperaron 942 registros (873 de Semantic Scholar y 69 de Crossref).
2. **Eliminación de duplicados.** Se eliminaron 64 duplicados, identificados por coincidencia de DOI o de título normalizado, y quedaron 878 registros únicos.
3. **Filtros previos al cribado.** Se excluyeron 242 registros por tipo de documento o por tratarse de preprints (CE1) y 44 sin resumen disponible (CE5).
4. **Cribado por título y resumen.** Se revisaron 592 registros y se excluyeron 497: 82 no abordaban robótica social ni HRI (CE2), 2 no integraban IA

Tabla 4. Criterios de inclusión (CI) y de exclusión (CE).

Cód.	Criterio
CI1	El estudio aborda robots sociales, socialmente asistivos o de compañía, o la HRI con un robot físico (P).
CI2	El robot integra IA generativa: LLM, VLM, modelos fundacionales o GPT (I).
CI3	La interacción es multimodal: combina al menos dos canales entre voz, texto, imagen, video, gesto, mirada, expresión facial o señales fisiológicas (I).
CI4	Reporta una evaluación empírica (estudio con usuarios, experimento, piloto o evaluación técnica) con resultados sobre latencia, comportamiento no verbal, desempeño cognitivo, aceptación, confianza o aspectos éticos (O).
CI5	Artículo de revista o de conferencia revisado por pares, publicado entre 2020 y 2026, en inglés o español.
CE1	Preprints sin revisión por pares, tesis, libros, capítulos, editoriales y otros documentos no indexados.
CE2	Robots sin función social o asistencial (conducción autónoma, manipulación industrial, logística o tareas domésticas sin interacción social).
CE3	Estudios sin robot físico: agentes virtuales, chatbots, interfaces, conjuntos de datos o retos de evaluación.
CE4	Estudios secundarios (revisiones), que se emplean solo como antecedentes.
CE5	Registros sin resumen disponible o informes cuyo texto completo no fue accesible.

generativa (CI2), 231 no describían interacción multimodal (CI3) y 182 no reportaban evaluación empírica ni resultados relacionados con los desenlaces de interés (CI4). El cribado se apoyó en reglas de palabras clave equivalentes a cada criterio, y sus resultados fueron revisados por los autores.

5. **Recuperación de textos completos.** Se buscó el texto completo de los 95 informes que superaron el cribado. Se usaron las versiones de acceso abierto del editor, Europe PMC, arXiv y repositorios institucionales. Se recuperaron 37 informes. Los 58 restantes no fueron accesibles (28 de IEEE Xplore, 13 de la ACM Digital Library, 8 de MDPI y 9 de otros editores) y se registraron como no recuperados (CE5).
6. **Elegibilidad a texto completo.** Se leyeron los 37 informes recuperados y se excluyeron 15: 8 sin robot físico (CE3), por ejemplo un auditó de sesgos sobre prompts, un dispositivo háptico o conjuntos de datos; 5 con robots sin función social (CE2); y 2 revisiones (CE4). La lectura completa cambió decisiones del cribado. Por ejemplo, Walker et al. (2025) se había descartado por el resumen, pero el texto completo muestra una evaluación con usuarios sobre el robot Pepper.
7. **Inclusión.** Se incluyeron 22 estudios primarios, publicados en 2023 (1), 2024 (2), 2025 (10) y 2026 (9). La Tabla 5 resume sus características.

2.8. Extracción de datos

Los datos de los 22 estudios incluidos se extrajeron de la lectura a texto completo y se registraron en el formulario *Formulario.Seminario-Ordaya.xlsx*, entregado como documento aparte. Cada fila corresponde a un estudio, y las columnas siguen las tres dimensiones del objetivo:

- datos bibliográficos y de diseño: referencia, año, tipo de estudio, plataforma robótica, población y número de participantes;
- dimensión técnica: modelo generativo, despliegue (nube, local o híbrido), modalidades de entrada y de salida, arquitectura de fusión, traducción de lenguaje a acción, latencia reportada y su mitigación, sincronización verbal–no verbal y robustez del reconocimiento de voz;
- dimensiones cognitiva y ética: limitaciones de razonamiento, riesgos éticos identificados y salvaguardas propuestas;
- cierre: métricas, resultados principales, limitaciones declaradas y dimensión abordada.

La Tabla 5 resume las características principales. Los estudios usan sobre todo Furhat (4), Pepper (4) y ARI (2), y siete se dirigen a adultos mayores. El modelo se despliega en la nube en 10 estudios, en local en 5 y de forma híbrida en 7. Siete estudios reportan tiempos cuantitativos. La latencia de respuesta conversacional va de 0,6 s con predicción de turnos (Skantze e Irfan, 2025) a 4,7 s tras optimizar el pipeline de voz, desde 9,8 s (Satake et al., 2026). La dimensión ética aparece en 11 estudios y la cognitiva en 5. Ningún estudio aborda las tres dimensiones a la vez, lo que confirma el vacío que motiva esta revisión.




Figura 1. Diagrama de flujo PRISMA 2020 del proceso de selección (adaptado de Page et al., 2021).

Tabla 5: Características de los estudios incluidos (n = 22).

N.º	Estudio	Plataforma	n	Modelo	Hallazgo principal	Dimensión
1	Abbo et al., 2026	Furhat	30	GPT-3.5 + Azure (identificación de hablante)	96 % considera que el robot siguió la conversación; 76,7 % juzgó natural su adecuación	Técnica+ Cognitiva
2	Ben Halima et al., 2026	Sistema robótico embebido de asistencia (Jetson Nano)	No reportado	LLaMA 3 local (Ollama) + YOLOv8n + Google Web Speech API	Funcionamiento en tiempo real en hardware de bajo coste	Técnica
3	Blavette et al., 2025a	ARI (PAL Robotics)	97	LLM integrado desde la oleada 2 (proyecto H2020 SPRING)	Mejoras en usabilidad y aceptabilidad tras integrar el LLM	Técnica+ Ética
4	Blavette et al., 2025b	ARI (PAL Robotics)	28	Vicuna-13B-v1.5 (sin conexión)	Aceptabilidad (12,8 a 20,8) y SUS (40,0 a 60,4) significativamente mayores en la oleada 2	Técnica+ Ética
5	Fujii et al., 2025	Androide Nikola (RIKEN)	> 600 (327 analizados)	GPT-4o	Las instrucciones abstractas favorecen la atribución de emociones	Técnica+ Ética
6	Galatolo y Winkle, 2025	Furhat y Pepper	No reportado	Modelos pequeños con “gesture heads” (comparados con LLaMA 3.1 70B)	Generación multimodal sin penalizar la velocidad de inferencia	Técnica
7	Kang et al., 2026	Robot social con rostro expresivo	8	LLM (bucle lento) + reconocimiento de emociones (bucle rápido)	Mejoras significativas en estabilidad, ánimo y empatía percibida	Técnica+ Ética
8	Kim et al., 2024	Pepper	32	GPT-3.5 (text-davinci-003)	El robot destaca en crear conexión y deliberar, pero falla en la comunicación lógica	Cognitiva+ Ética
9	Lai et al., 2025	Robot manipulador asistivo + gafas Meta ARIA	42	GPT-4o + Fast Whisper	Éxito > 94 % y mejor que todos los métodos base	Técnica
10	Liao et al., 2026	Kebbi (Nuwa Robotics)	22	GPT-4o (etapas de apoyo emocional) + modelo multimodal propio (DEPRESAR-Fusion)	El modelo propio supera a LLM zero-shot con menos parámetros; la inducción emocional mejora la detección	Técnica+ Ética
11	Liu et al., 2026	Robot móvil de compañía con cámara en gimbal (Jetson Orin)	10	GPT-4o Realtime API (voz) + VLM para seguridad	93,3 % (84/90) de éxito frente a 48,9 % del método base	Técnica+ Ética
12	Mishra et al., 2023	Furhat	47	GPT-3.5	La condición congruente obtuvo mejor percepción y puntuación que la neutra y la incongruente	Técnica

N.º	Estudio	Plataforma	n	Modelo	Hallazgo principal	Dimensión
13	Ok et al., 2026	LeeAhn 2, manipulador móvil de interiores	20 ensayos físicos	Whisper-small (ASR) + GPT-4o	Ejecución viable en robot real con recuperación de fallos	Técnica+ Cognitiva
14	Pinto y Belpaeme, 2025	Robot conversacional	5	Azure ASR + GPT-4o; comparación con Whisper	La recuperación del LLM se correlaciona con la comprensión percibida ($r = 0,78$)	Técnica+ Cognitiva
15	Rahimi et al., 2025	Pepper (despliegue)	No reportado (benchmarks)	USER-VLM 360° frente a LLaMA 3.2, LLaVA, Pixtral	Rendimiento competitivo con modelos mayores y menor coste	Técnica+ Ética
16	Satake et al., 2026	Sota (Vstone), robot de mesa	18 (ronda 1) / 17 (ronda 2)	GPT-4o	SUS de 56,2 a 66,9 (significativo); la latencia traslada esfuerzo al usuario	Técnica+ Ética
17	Skantze e Irfan, 2025	Furhat	39	LLM para respuestas + TurnGPT y Voice Activity Projection (VAP) para turnos	Preferencia significativa por el sistema propuesto; menos retardos e interrupciones	Técnica
18	Viet et al., 2025	Prototipo humanoide (12 GDL en brazos, cabeza con pantalla LCD expresiva, Jetson)	No reportado	Gemini API (análisis semántico) + MediaPipe/ LSTM + YOLO	Exactitud > 90 %; gestos 96 %; voz 92 %; error de manipulación $\approx 1,83$ cm	Técnica
19	Walker et al., 2025	Pepper	20	GPT (variantes verbal y tripletas) y Llama-2-13B	GPT-verbal obtuvo la mejor facticidad; sin diferencia significativa entre Llama y tripletas	Técnica+ Cognitiva
20	Wang et al., 2024	Haru (Honda), robot de mesa	12	Llama-2-Chat 70B (local, cuantización GPTQ 4 bits)	El sistema fue disfrutable; errores dominados por el ASR	Técnica+ Ética
21	Wang et al., 2026	Stretch 3 (Hello Robot)	18	LLM para interpretar modificaciones de trayectoria	Los participantes modificaron trayectorias en tiempo real; preferencia por la comunicación bidireccional	Técnica+ Ética
22	Yang et al., 2026	MiRo-E	10	gpt-4o-mini con ajuste fino (adaptativo y no adaptativo) + Azure Speech	El modo adaptativo mejoró la experiencia y el éxito de la tarea	Técnica

Referencias

1. Abbo, G. A., Desideri, G., Belpaeme, T., y Spitale, M. (2025). “Can you be my mum?”: Manipulating social robots in the large language models era. En *Proceedings of the 2025 ACM/IEEE International Conference on Human-Robot Interaction (HRI)* (pp. 1181–1185). IEEE.

2. Abercrombie, G., Cercas Curry, A., Dinkar, T., Rieser, V., y Talat, Z. (2023). Mirages: On anthropomorphism in dialogue systems. En *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing* (pp. 4776–4790). <https://doi.org/10.18653/v1/2023.emnlp-main.290>
3. Barakat, H., Turk, O., y Demiroglu, C. (2024). Deep learning-based expressive speech synthesis: A systematic review of approaches, challenges, and resources. *EURASIP Journal on Audio, Speech, and Music Processing*, 2024 (1), 1–34. <https://doi.org/10.1186/s13636-024-00329-7>
4. Hendricks, G., Tkaczyk, D., Lin, J., y Feeney, P. (2020). Crossref: The sustainable source of community-owned scholarly metadata. *Quantitative Science Studies*, 1(1), 414–427. https://doi.org/10.1162/qss_a_00022
5. Kim, C. Y., Lee, C. P., y Mutlu, B. (2024). Understanding large-language model (LLM)-powered human-robot interaction. En *Proceedings of the 2024 ACM/IEEE International Conference on Human-Robot Interaction* (pp. 371–380). <https://doi.org/10.1145/3610977.3634966>
6. Kinney, R., Anastasiades, C., Authur, R., Beltagy, I., Bragg, J., Buraczynski, A., . . . Weld, D. S. (2023). *The Semantic Scholar Open Data Platform* (arXiv:2301.10140). arXiv. <https://doi.org/10.48550/arXiv.2301.10140>
7. Kitchenham, B., y Charters, S. (2007). *Guidelines for performing systematic literature reviews in software engineering* (EBSE Technical Report EBSE-2007-01). Keele University y Durham University.
8. Lai, Y., Yuan, S., Nassar, Y., Fan, M., Weber, T., y Rättsch, M. (2025). NVP-HRI: Zero shot natural voice and posture-based human–robot interaction via large language model. *Expert Systems with Applications*, 268, 126360. <https://doi.org/10.1016/j.eswa.2025.126360>
9. Maure, R., y Bruno, B. (2025). Autonomy in socially assistive robotics: A systematic review. *Frontiers in Robotics and AI*, 12, 1586473. <https://doi.org/10.3389/frobt.2025.1586473>
10. Mauliana, M., Ashok, A., Czernochowski, D., y Berns, K. (2025). Exploring LLM-powered multi-session human-robot interactions with university students. *Frontiers in Robotics and AI*, 12, 1585589. <https://doi.org/10.3389/frobt.2025.1585589>
11. Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., . . . Moher, D. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372, n71. <https://doi.org/10.1136/bmj.n71>
12. Santos, C. M. C., Pimenta, C. A. M., y Nobre, M. R. C. (2007). The PICO strategy for the research question construction and evidence search. *Revista Latino-Americana de Enfermagem*, 15(3), 508–511. <https://doi.org/10.1590/S0104-11692007000300023>
13. Verhelst, E., y Belpaeme, T. (2025). Large language models cover for speech recognition mistakes: Evaluating conversational AI for second language learners. En *Proceedings of the 2025 ACM/IEEE International Conference on Human-Robot Interaction (HRI)* (pp. 1705–1709). IEEE.
14. Verma, M., Bhambri, S., y Kambhampati, S. (2024). Theory of mind abilities of large language models in human-robot interaction: An illusion? En *Companion of the 2024 ACM/IEEE International Conference on Human-Robot Interaction* (pp. 37–45). <https://doi.org/10.1145/3610978.3640767>
15. Zhang, B., y Soh, H. (2023). Large language models as zero-shot human models for human-robot interaction. En *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* (pp. 7961–7968). <https://doi.org/10.1109/IROS55552.2023.10341488>

Estudios incluidos en la RSL

1. Abbo, G. A., Pinto-Bernal, M. J., Catrycke, M., y Belpaeme, T. (2026). Multi-party open-ended conversation with a social robot. *Frontiers in Robotics and AI*. <https://doi.org/10.3389/frobt.2026.1766383>
2. Ben Halima, S., Ben Abdallah, F., y Haggège, J. (2026). Edge AI-Based Object Detection via Voice Recognition with an LLM-Based Emotional Assistant for Elderly Care Robots. *International Journal of Information Technology and Computer Science*. <https://doi.org/10.5815/ijitcs.2026.04.04>
3. Blavette, L., Dacunha, S., Alameda-Pineda, X., García, D. H., Gannot, S., Gras, F., Gunson, N., Lemaignan, S., Polic, M., Tandeitnik, P., Tonini, F., Rigaud, A., y Pino, M. (2025a). Acceptability and Usability of a Socially Assistive Robot Integrated With a Large Language Model for Enhanced Human-Robot Interaction in a Geriatric Care Institution: Mixed Methods Evaluation. *JMIR Human Factors*. <https://doi.org/10.2196/76496>
4. Blavette, L., Dacunha, S., Alameda-Pineda, X., Cattoni, J., Rigaud, A., y Pino, M. (2025b). Integrating a Large Language Model Into a Socially Assistive Robot in a Hospital Geriatric Unit: Two-Wave Comparative Study on Performance, Engagement, and User Perceptions. *JMIR Human Factors*. <https://doi.org/10.2196/81936>
5. Fujii, A., Ishi, C., Sakai, K., Funayama, T., Iwai, R., Takahashi, Y., Kumada, T., y Minato, T. (2025). Evaluating human perceptions of android robot facial expressions based on variations in instruction styles. *Frontiers in Robotics and AI*. <https://doi.org/10.3389/frobt.2025.1728647>
6. Galatolo, A., y Winkle, K. (2025). Simultaneous text and gesture generation for social robots with small language models. *Frontiers in Robotics and AI*. <https://doi.org/10.3389/frobt.2025.1581024>
7. Kang, C., Alitai, M., Wang, Y., Cai, X., Ma, R., Cangelosi, A., y Shangguan, Z. (2026). Fluid-Xpress: Emotion-Aware Dual-Loop Framework for Empathic Facial Reaction in HRI. *Companion Proceedings of the 21st ACM/IEEE International Conference on Human-Robot Interaction*. <https://doi.org/10.1145/3776734.3794429>
8. Kim, C. Y., Lee, C. P., y Mutlu, B. (2024). Understanding Large-Language Model (LLM)-powered Human-Robot Interaction. *2024 19th ACM/IEEE International Conference on Human-Robot Interaction (HRI)*. <https://doi.org/10.1145/3610977.3634966>
9. Lai, Y., Yuan, S., Li, P., Zhang, B., Kiefer, B., Deng, T., y Zell, A. (2025). FAM-HRI: Foundation-Model Assisted Multimodal Human-Robot Interaction Combining Gaze and Speech. *IEEE Transactions on Automation Science and Engineering*. <https://doi.org/10.1109/tase.2026.3695438>
10. Liao, P., Su, Y., Qian, X., Chang, Y., Lee, Y., y Fu, L. (2026). Multimodal Depression Detection Through Conversational Interactions with an Emotion-Aware Social Robot: Pilot Study. *JMIR Formative Research*. <https://doi.org/10.2196/84110>
11. Liu, C., Vu, C., y Liu, Y. (2026). Multimodal-Language-Model-Driven Interaction and Companionship for Service Robots in Elderly-Care Facilities. *2026 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM)*. <https://doi.org/10.1109/aim65483.2026.11658058>
12. Mishra, C., Verdonschot, R. G., Hagoort, P., y Skantze, G. (2023). Real-time emotion generation in human-robot dialogue using large language models. *Frontiers in Robotics and AI*. <https://doi.org/10.3389/frobt.2023.1271610>

13. Ok, K., Heo, G., Lee, C., y Ahn, S. (2026). Practical Human–Robot Interaction (HRI) through Large Language Model (LLM)-based Voice-to-Action Systems. *International Journal of Precision Engineering and Manufacturing*. <https://doi.org/10.1007/s12541-026-01573-x>
14. Pinto, M. J., y Belpaeme, T. (2025). Speech Recognition and LLM Performance in Elderly Care Home Conversations. *2025 34th IEEE International Conference on Robot and Human Interactive Communication (RO-MAN)*. <https://doi.org/10.1109/ro-man63969.2025.11217575>
15. Rahimi, H., Bahaj, A., Abrini, M., Khoramshahi, M., Ghogho, M., y Chetouani, M. (2025). USER-VLM 360: Personalized Vision Language Models with User-aware Tuning for Social Human-Robot Interactions. *Proceedings of the 27th International Conference on Multimodal Interaction*. <https://doi.org/10.1145/3716553.3750767>
16. Satake, Y., Nygren, M., Yu, C., Tsuboi, A., Endo, I., Umemura, K., Katsuki, K., Ishimaru, D., Rapaport, P., Bianchi-Berthouze, N., Ikeda, M., y Howard, R. (2026). Focus Group-Led Refinement of an LLM-Enabled Companion Robot for Older People. *International Journal of Social Robotics*. <https://doi.org/10.1007/s12369-026-01407-w>
17. Skantze, G., y Irfan, B. (2025). Applying General Turn-Taking Models to Conversational Human-Robot Interaction. *2025 20th ACM/IEEE International Conference on Human-Robot Interaction (HRI)*. <https://doi.org/10.1109/hri61500.2025.10973958>
18. Viet, T. T., Canh, T., Gia, H. U., Van, P. D., Duc, S. T., Do, N. M., y Hoang-Van, X. (2025). Development of a Humanoid Robot Prototype for Multimodal Human-Robot Interaction. *2025 RIVF International Conference on Computing and Communication Technologies (RIVF)*. <https://doi.org/10.1109/rivf68649.2025.11364526>
19. Walker, N., Ultes, S., y Lison, P. (2025). Graph-to-Text Approach to Knowledge-Grounded Response Generation in Human-Robot Interaction. *Dialogue Discourse*. <https://doi.org/10.5210/dad.2025.304>
20. Wang, Z., Reisert, P., Nichols, E., y Gomez, R. (2024). Ain't Misbehavin' - Using LLMs to Generate Expressive Robot Behavior in Conversations with the Tabletop Robot Haru. *Companion of the 2024 ACM/IEEE International Conference on Human-Robot Interaction*. <https://doi.org/10.1145/3610978.3640562>
21. Wang, J., Wang, C., Zarrin, R. S., y Erickson, Z. (2026). Bidirectional Human-Robot Communication for Physical Human-Robot Interaction. *Proceedings of the 21st ACM/IEEE International Conference on Human-Robot Interaction*. <https://doi.org/10.1145/3757279.3785634>
22. Yang, Y., Yap, P. S., Wijekumar, S., Magassouba, A., y Deshpande, N. (2026). A Multimodal Adaptive Framework for Social Interaction with the MiRo-E Robot. *Sensors (Basel, Switzerland)*. <https://doi.org/10.3390/s26041209>